

# Análisis estadístico de datos de Spotify 2015-2025

Diego Hernández Rodríguez C311  
Fabián A. Almeida Martínez C311

28 de enero de 2026

## 1. Introducción

Este proyecto consiste en un análisis de los datos de Spotify en el rango de 2015-2025 tomando la popularidad, disponibilidad... como variables objetivo del análisis para responder preguntas muy comunes entre todas las personas que dedicamos horas de escucha a la música día a día.


Entre las preguntas a responder tenemos:

- ¿La disponibilidad afecta directamente a la popularidad?
- ¿Qué diferencias de popularidad podemos encontrar entre los diferentes géneros?
- ¿Cómo predecir los streams de una canción en su primer mes basado en variables del artista y lanzamiento?
- ¿Cómo se puede evidenciar la evolución de la música a través de los años?

## 2. Análisis Exploratorio: Relación entre Popularidad y Danceability


Es muy común pensar que mientras másailable sea una canción más popular tiende a ser, por lo cual nosotros con este proyecto nos dimos la tarea de responder esta pregunta. Para ello decidimos realizar un Análisis Exploratorio de Datos exhaustivo para ver la relación directa entre popularidad y bailabilidad que existe en la música en el periodo de 2015-2025. Entre los resultados de nuestro análisis pudimos ver lo siguiente:

### 2.1. Las Distribuciones de popularidad y bailabilidad en nuestra base de datos:




La popularidad presenta una media de 48.2 puntos en una escala de 0 a 100, indicando un nivel moderado de popularidad promedio en el dataset. La danceability muestra una media de 0.521 en escala de 0 a 1, sugiriendo que la mayoría de las canciones tienen valores intermedios de bailabilidad. Ambas variables exhiben rangos completos en sus respectivas escalas, confirmando la diversidad del dataset analizado.

## 2.2. La relación directa entre popularidad y bailabilidad que existe en la música en este rango de tiempo:



El mapa de densidad conjunta confirma la débil relación lineal entre las variables, con puntos distribuidos ampliamente en todo el rango. Este patrón sugiere que la industria musical produce principalmente contenido con características acústicas moderadas, buscando un balance que pueda atraer a audiencias amplias sin especializarse en extremos. La popularidad parece depender de factores más allá de la bailabilidad intrínseca de la canción.




El análisis por quintiles de danceability muestra un patrón no monótono en la popularidad promedio. Contrario a la hipótesis inicial, el quintil con danceability media (Q3) presenta la mayor popularidad (57.0), mientras que el quintil Q2 muestra la menor (42.0). La diferencia máxima entre quintiles es de 15 puntos de popularidad, indicando que la danceability explica solo una porción limitada de la variabilidad en popularidad.

El análisis estadístico demuestra que la relación entre danceability y popularidad en Spotify (2015-2025) es débil y no determinante. Si bien existe una correlación estadísticamente significativa, su magnitud es insuficiente para afirmar que canciones más bailables sean sistemáticamente más populares. La popularidad depende de múltiples factores que trascienden las características acústicas individuales.

### 3. Kruskal-Wallis: Diferencias de Popularidad entre Géneros Musicales

Kruskal-Wallis y ANOVA son métodos usados para ver diferencias entre 3 o más grupos independientes. En este caso, dada la no normalización de los datos de Spotify es necesario usar Kruskal-Wallis ya que es no paramétrico. Su utilidad principal en nuestro análisis radica en que nos permite determinar si existen diferencias estadísticamente significativas en la popularidad de las canciones entre los distintos géneros musicales.

Luego de aplicar el algoritmo llegamos a la siguiente tabla:



Estos resultados revelan que sí existen diferencias estadísticamente significativas en la popularidad entre géneros musicales en Spotify. Las preferencias de los usuarios no se distribuyen uniformemente, sino que muestran claras inclinaciones hacia géneros contemporáneos y urbanos.


El análisis con Kruskal-Wallis nos proporciona la evidencia estadística para afirmar que el género musical sí es un factor que influye en los niveles de popularidad de las canciones en la plataforma, permitiéndonos identificar qué géneros tienden a alcanzar mayor audiencia y cuáles tienen una popularidad

más limitada.

Estas diferencias reflejan preferencias del mercado actual, tendencias culturales y algoritmos de recomendación de plataformas de streaming, donde géneros contemporáneos y urbanos dominan sobre géneros clásicos y de nicho.


## 4. Regresión Lineal: Predecir Streams del Primer Mes

Otra duda que nos surgió era ver si era posible predecir los streams del primer mes de una canción basándonos en los datos del artista y del lanzamiento de la canción. Para ello usamos una regresión lineal. Nosotros queríamos saber no solo qué factores influyen en los streams, sino exactamente cuánto influye cada uno y la regresión lineal nos da precisamente eso, proporcionando coeficientes numéricos que nos dicen "por cada unidad que aumenta la popularidad, los streams aumentan X cantidad". Esta precisión es invaluable para tomar decisiones basadas en datos.



Los hallazgos más importantes revelan que la popularidad actual de la canción es el factor más determinante, con un impacto muy fuerte. También descubrimos que el historial previo del artista es importante, pero de manera interesante, encontramos que los artistas con popularidad muy consistente tienden a tener un rendimiento ligeramente menor en nuevos lanzamientos. Además, confirmamos que lanzar en fin de semana ofrece una pequeña ventaja.

Un hallazgo clave es que las características del artista y el timing del lanzamiento son mucho más importantes para predecir el éxito comercial inmediato que las características musicales intrínsecas como la bailabilidad o el tempo. Esto nos dice que en la industria musical actual, factores externos como la promoción, la marca del artista y el momento estratégico del lanzamiento pesan más que la calidad musical pura a la hora de generar streams rápidamente.



Estas gráficas muestran qué tan bien se ajustan las predicciones de nuestro modelo a los datos reales de streams. En el eje horizontal están los valores reales de streams transformados logarítmicamente, y en el eje vertical están los valores predichos por nuestro modelo, también en escala logarítmica.


Lo que vemos en la primera figura es una nube de puntos azules que representan cada canción en nuestro análisis. La línea roja discontinua marca el ideal donde las predicciones serían perfectamente iguales a los valores reales. La buena noticia es que la mayoría de puntos se agrupan cerca de esta línea roja, lo que significa que nuestro modelo está haciendo predicciones bastante acertadas.

La forma del histograma es aproximadamente una campana de Gauss centrada en el cero, que es exactamente lo que esperaríamos si nuestro modelo es bueno. La línea roja vertical marca el punto de error cero, y vemos que la distribución está bien centrada aquí, lo que significa que en promedio nuestro modelo no comete errores sistemáticos de sobreestimar o subestimar.

El modelo de regresión lineal que desarrollamos logró un resultado muy sólido, explicando el  $R^2 = 0,592$  de la variabilidad en los streams del primer mes. Esto significa que podemos predecir con bastante precisión cuántos streams tendrá una canción en su primer mes basándonos en variables clave.

## 5. PCA + Clustering: Analizar Evolución Musical 2015-2025

Utilizamos PCA combinado con Clustering para responder a la pregunta: ¿Cómo han evolucionado los patrones y estilos musicales desde 2015 hasta 2025? Lo cual es un buen empleo de dicho algoritmo ya que PCA reduce la dimensionalidad de múltiples características musicales (danceability, energy, tempo, etc.) permitiendo visualizar y analizar patrones complejos en solo 2-3 dimensiones y Clustering agrupa automáticamente canciones con perfiles similares, identificando estilos musicales sin necesidad de etiquetas previas. La combinación permite analizar tanto la estructura de los estilos musicales como su evolución temporal simultáneamente.



Se aplicó análisis PCA para reducir 6 características musicales a componentes principales, seguido de clustering K-means para identificar con el Elbow Method, como cantidad óptima, 4 grupos de estilos musicales entre 2015-2025:

- **Cluster 0:** Música energética con alta instrumentalidad (-14dB loudness, 130BPM)
- **Cluster 1:** Baladas suaves con tempo lento (-31dB, 94BPM)
- **Cluster 2:** Música ambiental instrumental (-42dB, alta instrumentalidad)
- **Cluster 3:** Música dance rápida (166BPM, tempo más alto)



Dado esto podemos concluir que los 4 clusters representan patrones musicales consistentes que persisten durante 10 años, puesto que no hay cambios radicales en preferencias musicales 2015-2025. Los Clusters 0 y 3 (música energética y dance) dominan el mercado mientras que 1 y 2 mantienen nichos estables especializados. Como resultados de analizar cada cluster podemos ver que el 0 es el estilo más popular en 8 de los 11 años, el 1 es el estilo menos variable, muy nicho y consistente, el 2 tuvo un repunte interesante en 2024, aunque no sigue modas pasajeras y por último el 3 con crecimiento constante desde 2015 hasta 2025, se volvió más popular con el tiempo, alcanzando casi la popularidad de 0.

## 6. Conclusión

Ya aplicados los algoritmos previos hemos sido capaces de responder satisfactoriamente las preguntas realizadas en un inicio, las cuales podrían ser la duda de cualquiera. A modo de resumen, podemos concluir que la popularidad está determinada por muchos más factores que no se encuentran entre las características acústicas de una canción. Ejemplo de esto es que la bailabilidad no afecta necesariamente a la popularidad y que para hacer una predicción de streams influye más la popularidad del artista que saca la canción y la fecha de lanzamiento que el género al que pertenezca.

También fuimos capaces de determinar cómo entre los géneros hay mucha diferencia de popularidad, así para ver los géneros más populares o los que menos crean tendencia, pero sobre todo fuimos capaces de ver cómo todas estas tendencias se mantienen por todo el periodo de 2015-2025 con poca variación.

**En síntesis, este estudio revela que la industria musical actual está definida más por factores externos (promoción, marca del artista, timing estratégico) que por cualidades musicales intrínsecas. Sin embargo, el análisis de evolución temporal muestra una estabilidad notable en los gustos del público, con cuatro perfiles musicales claros que coexisten y se mantienen relevantes a lo largo de una década. Estos hallazgos proporcionan una visión valiosa para artistas, productores y plataformas de streaming que buscan entender y navegar el complejo panorama musical contemporáneo.**